

PROJET FINAL

Système de Reconnaissance d'Émotions Faciales

*Pipeline : Détection de visage (Haar Cascade) → Embeddings (FaceNet) → Classification (SVM) →
Déploiement (Streamlit)*

Préparé par : Ibrahim
Programme de Science des Données
Date : 3 juillet 2026

1. Objectif du projet

Ce projet vise à démontrer la maîtrise des compétences en science des données et en vision par ordinateur acquises durant la formation, à travers la conception complète d'un système de reconnaissance d'émotions faciales. L'objectif est de construire un pipeline de bout en bout : collecte et prétraitement des données, extraction de caractéristiques via un modèle de deep learning pré-entraîné, classification par apprentissage automatique, puis déploiement d'une application fonctionnelle.

Le système final est capable de détecter un visage sur une image et de prédire l'émotion exprimée parmi sept catégories universelles : colère (angry), dégoût (disgust), peur (fear), joie (happy), neutre (neutral), tristesse (sad) et surprise (surprise).

2. Méthodologie

Le projet suit un pipeline en trois phases, structuré selon les instructions fournies par l'instructeur.

2.1 Phase 1 — Collecte et prétraitement des données

Le dataset utilisé est FER2013 (Facial Expression Recognition 2013), un jeu de données académique standard contenant des milliers d'images de visages en niveaux de gris (48×48 pixels), réparties en 7 classes d'émotions. Un sous-ensemble équilibré a été constitué (300 images par classe pour l'entraînement, 60 pour le test), organisé selon une structure de dossiers où chaque sous-répertoire correspond à une émotion.

Trois fonctions ont été développées conformément aux spécifications :

- `extract_face(filename, required_size)` : détection et extraction du visage via le modèle Haar Cascade (OpenCV), avec redimensionnement à la taille requise
- `load_faces(directory)` : application de `extract_face` à l'ensemble des images d'un répertoire
- `load_dataset(directory)` : parcours des sous-répertoires et association de l'étiquette (nom du sous-dossier) à chaque visage extrait

Les visages extraits et leurs étiquettes ont été sauvegardés dans un fichier compressé unique (`emotions_dataset.npz`), contenant les ensembles d'entraînement et de test.

2.2 Phase 2 — Extraction de caractéristiques (embeddings)

Le modèle FaceNet (via la librairie `keras-facenet`) a été utilisé comme extracteur de caractéristiques. La fonction `get_embedding` calcule, pour chaque visage, un vecteur d'embedding de dimension 512, après conversion des images en RGB et redimensionnement à 160×160 pixels (format attendu par FaceNet). Une alternative utilisant VGG16 pré-entraîné (Keras) a également été implémentée et documentée.

Les embeddings de l'ensemble d'entraînement et de test ont été sauvegardés dans un fichier `emotions_embeddings.npz`.

2.3 Phase 3 — Modélisation et déploiement

Un classifieur SVM (Support Vector Machine) a été entraîné sur les embeddings, avec une recherche d'hyperparamètres par validation croisée (`GridSearchCV`) portant sur le noyau (rbf), le paramètre de

régularisation C et le paramètre gamma. Trois autres classifieurs ont été testés à des fins de comparaison : K-Nearest Neighbors, Random Forest et Régression Logistique. Le meilleur modèle a ensuite été déployé dans une application Streamlit permettant de tester le système sur une nouvelle image.

3. Résultats

3.1 Performance du modèle SVM (meilleur modèle)

Après recherche d'hyperparamètres, la meilleure configuration obtenue est : noyau RBF, C = 10, gamma = 'scale', avec un score de validation croisée de 38.6 %.

Évaluation sur l'ensemble de test :

Métrique	Valeur
Accuracy	43.10 %
F1-score macro	42.72 %

Rapport de classification détaillé, par émotion :

Émotion	Précision	Rappel	F1-score	Support
angry	0.39	0.47	0.42	60
disgust	0.65	0.68	0.67	60
fear	0.29	0.28	0.29	60
happy	0.47	0.55	0.51	60
neutral	0.37	0.37	0.37	60
sad	0.35	0.28	0.31	60
surprise	0.47	0.38	0.42	60

3.2 Comparaison des classifieurs

Afin de déterminer si les performances observées étaient liées au choix de l'algorithme ou à la nature des caractéristiques (embeddings), quatre classifieurs ont été comparés sur les mêmes données :

Classifieur	Accuracy	F1-macro
SVM (RBF)	43.10 %	42.72 %
Random Forest	39.05 %	38.69 %
KNN	37.62 %	37.16 %
Régression Logistique	32.38 %	31.80 %

L'ensemble des classifieurs obtient des performances comprises dans une fourchette resserrée (32 % à 43 %), malgré des principes de fonctionnement très différents. Ce constat indique que la limite de performance ne provient pas du choix de l'algorithme de classification, mais de la nature des caractéristiques utilisées en entrée.

4. Analyse critique

Les résultats obtenus (43 % d'accuracy sur 7 classes équilibrées, contre environ 14 % pour une prédiction aléatoire) montrent que le système fait significativement mieux que le hasard, mais reste loin des performances qu'obtiendrait un réseau de neurones convolutif entraîné directement sur les pixels des images (généralement 65-70 % sur FER2013).

Cette limitation s'explique par la nature même du modèle FaceNet utilisé pour l'extraction de caractéristiques. FaceNet est entraîné spécifiquement pour la reconnaissance d'identité, avec un objectif d'invariance à l'expression faciale : deux photos de la même personne, souriante ou non, doivent produire des embeddings proches. Cette propriété, essentielle pour la reconnaissance faciale, devient une limite structurelle pour la tâche de reconnaissance d'émotions, puisque le modèle a précisément appris à minimiser l'information liée à l'expression du visage.

L'analyse par classe révèle également des tendances cohérentes avec la littérature sur FER2013 : les émotions à expression très marquée (dégoût, joie) sont mieux reconnues (F1-score de 0.67 et 0.51 respectivement), tandis que les émotions aux signatures visuelles proches (peur et tristesse, souvent confondues avec la surprise ou la neutralité) obtiennent des scores plus faibles (F1-score de 0.29 et 0.31). Cette confusion entre peur et tristesse est documentée dans plusieurs études sur ce dataset, y compris pour des modèles entraînés directement sur les pixels.

5. Déploiement

Le meilleur modèle (SVM) a été déployé dans une application Streamlit reproduisant le pipeline complet : chargement d'une image par l'utilisateur, détection du visage (Haar Cascade), calcul de l'embedding (FaceNet), puis prédiction de l'émotion avec affichage du score de confiance et de la répartition des probabilités par classe.

L'application a été conçue pour être déployée sur Streamlit Community Cloud, permettant un partage simple du lien avec l'instructeur.

6. Conclusion et perspectives

Ce projet a permis de mettre en œuvre un pipeline complet de reconnaissance d'émotions faciales, en suivant rigoureusement les étapes définies par l'instructeur : collecte et prétraitement des données, extraction de caractéristiques par un modèle pré-entraîné, modélisation par apprentissage automatique, et déploiement d'une application fonctionnelle.

Les résultats obtenus, bien que limités en performance absolue, sont cohérents avec les propriétés connues du modèle FaceNet et ont été analysés de manière critique plutôt que présentés sans recul. Cette analyse constitue en soi une valeur ajoutée du projet, démontrant une compréhension du

fonctionnement des modèles utilisés au-delà de leur simple mise en œuvre.

Plusieurs pistes d'amélioration ont été identifiées pour de futurs travaux :

- Entraîner un CNN directement sur les pixels des images, sans passer par des embeddings pré-entraînés pour l'identité
- Utiliser un modèle d'embedding spécifiquement entraîné pour la reconnaissance d'expressions faciales plutôt que pour l'identité
- Enrichir le dataset avec des techniques d'augmentation de données
- Explorer des architectures de deep learning plus récentes (Vision Transformers, EfficientNet)